

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Инфорт	матика и системы управле	ения	
КАФЕДРА Системы об	бработки информации и у	правления	
Отчёт по рубежному контролю №1			
По дисциплине: «Технологии машинного обучения»			
WI CAHOMOT P	in maintinoto doy terimin		
Выполнил:			
Студент группы ИУ5-61Б		_ Шевчук М.С	
	(Подпись, дата)	(Фамилия И.О.)	
Проверил:			
<u>.</u>		Гапанюк Ю. Е.	
	(Подпись, дата)	(Фамилия И.О.)	

Задание

Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы

использовали для решения задачи и почему?

Для студентов групп ИУ5-61Б, ИУ5Ц-81Б - для пары произвольных колонок данных построить график "Диаграмма рассеяния". Набор данных:

https://www.kaggle.com/noriuk/us-education-datasets-unification-project (файл states_all.csv)

РК ИУ5-61Б


Импорт библиотек

```
In [1]: import numpy as np
         import pandas as pd
         import seaborn as sns
         import matplotlib.pyplot as plt
         from pandas.plotting import scatter_matrix
         from sklearn.impute import SimpleImputer
         from sklearn.impute import MissingIndicator
         import warnings
         warnings.filterwarnings('ignore')
         sns.set(style="ticks")
         *matplotlib inline
In [2]: data = pd.read_csv('states_all.csv')
In [3]: data.head()
             PRIMARY_KEY
                              STATE YEAR ENROLL TOTAL_REVENUE FEDERAL_REVENUE S'
Out[3]:
        0
            1992_ALABAMA
                            ALABAMA
                                     1992
                                              NaN
                                                        2678885.0
                                                                           304177.0
                             ALASKA 1992
                                              NaN
                                                        1049591.0
                                                                           106780.0
        1
             1992_ALASKA
        2
            1992_ARIZONA
                            ARIZONA 1992
                                              NaN
                                                        3258079.0
                                                                          297888.0
        3 1992_ARKANSAS ARKANSAS
                                                        1711959.0
                                                                           178571.0
                                     1992
                                              NaN
        4 1992_CALIFORNIA CALIFORNIA 1992
                                              NaN
                                                       26260025.0
                                                                         2072470.0
       5 rows x 25 columns
In [4]: data.dtypes
```

```
Out[4]: PRIMARY_KEY
        STATE
                                        object
        YEAR
                                         int64
        ENROLL
                                       float64
        TOTAL REVENUE
                                       float64
        FEDERAL REVENUE
                                       float64
        STATE_REVENUE
                                       float64
        LOCAL REVENUE
                                       float64
        TOTAL EXPENDITURE
                                       float64
        INSTRUCTION_EXPENDITURE
                                       float64
        SUPPORT SERVICES EXPENDITURE
                                       float64
        OTHER EXPENDITURE
                                       float64
        CAPITAL_OUTLAY_EXPENDITURE
                                       float64
        GRADES PK G
                                       float64
        GRADES KG G
                                       float64
        GRADES 4 G
                                       float64
        GRADES 8 G
                                       float64
        GRADES 12 G
                                       float64
        GRADES 1 8 G
                                       float64
        GRADES 9 12 G
                                       float64
        GRADES ALL G
                                       float64
        AVG MATH 4 SCORE
                                       float64
        AVG_MATH_8_SCORE
                                       float64
                                       float64
        AVG_READING_4_SCORE
        AVG READING 8 SCORE
                                       float64
        dtype: object
In [5]: data.isnull().sum()
        # проверим есть ли пропущенные значения
Out[5]: PRIMARY_KEY
                                           0
        STATE
                                          0
        YEAR
                                          0
        ENROLL
                                        491
        TOTAL REVENUE
                                         440
        FEDERAL REVENUE
                                        440
        STATE REVENUE
                                        440
        LOCAL_REVENUE
                                        440
        TOTAL EXPENDITURE
                                        440
        INSTRUCTION EXPENDITURE
                                        440
        SUPPORT SERVICES EXPENDITURE
                                        440
        OTHER EXPENDITURE
                                        491
        CAPITAL_OUTLAY_EXPENDITURE
                                        440
        GRADES PK G
                                        173
        GRADES_KG_G
                                         83
        GRADES_4_G
                                         83
        GRADES 8 G
                                         83
        GRADES 12 G
                                         83
        GRADES 1 8 G
                                        695
                                        644
        GRADES_9_12_G
        GRADES ALL G
                                         83
        AVG_MATH_4_SCORE
                                       1150
        AVG MATH 8 SCORE
                                       1113
        AVG_READING_4_SCORE
                                       1065
        AVG READING 8 SCORE
                                       1153
        dtype: int64
In [6]: data.info()
```

object

```
<class 'pandas.core.frame.DataFrame'>
         RangeIndex: 1715 entries, 0 to 1714
         Data columns (total 25 columns):
                                            Non-Null Count Dtype
          # Column
             PRIMARY KEY
          0
                                            1715 non-null
                                                            object
          1
              STATE
                                            1715 non-null
                                                            object
          2
              YEAR
                                            1715 non-null
                                                            int64
          3
              ENROLL
                                            1224 non-null
                                                            float64
              TOTAL REVENUE
                                            1275 non-null
          4
                                                            float64
          5
             FEDERAL REVENUE
                                            1275 non-null
                                                            float64
              STATE REVENUE
                                            1275 non-null
                                                            float64
          6
              LOCAL_REVENUE
                                            1275 non-null
                                                            float64
          8
             TOTAL EXPENDITURE
                                           1275 non-null
                                                            float64
             INSTRUCTION EXPENDITURE
          9
                                            1275 non-null
                                                            float64
          10 SUPPORT_SERVICES_EXPENDITURE 1275 non-null
                                                            float64
          11 OTHER EXPENDITURE
                                            1224 non-null
                                                            float64
          12 CAPITAL_OUTLAY_EXPENDITURE
                                            1275 non-null
                                                            float64
          13 GRADES PK G
                                            1542 non-null
                                                            float64
          14 GRADES KG G
                                            1632 non-null
                                                            float64
          15 GRADES_4_G
                                            1632 non-null
                                                            float64
          16
              GRADES 8 G
                                            1632 non-null
                                                            float64
          17 GRADES 12 G
                                            1632 non-null
                                                            float64
          18 GRADES_1_8_G
                                            1020 non-null
                                                            float64
          19
              GRADES 9 12 G
                                            1071 non-null
                                                            float64
          20 GRADES ALL G
                                            1632 non-null
                                                            float64
          21 AVG_MATH_4_SCORE
                                            565 non-null
                                                            float64
          22 AVG_MATH_8_SCORE
                                            602 non-null
                                                            float64
          23 AVG_READING_4_SCORE
                                            650 non-null
                                                           float64
          24 AVG_READING_8_SCORE
                                            562 non-null
                                                            float64
         dtypes: float64(22), int64(1), object(2)
         memory usage: 335.1+ KB
 In [7]: from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
 In [8]: sc1 = MinMaxScaler()
          scl_data = scl.fit_transform(data[['ENROLL']])
         plt.hist(data['ENROLL'], 50)
 In [9]:
         plt.show()
         200
         150
         100
          50
In [10]: plt.hist(scl_data, 50)
          plt.show()
```



Масштабирование данных на основе Z-оценки - StandardScaler¶

In [13]: cat_temp_data = data[['STATE']]
cat_temp_data.head()

Out[13]: STATE

50

- 0 ALABAMA
- 1 ALASKA
- 2 ARIZONA
- 3 ARKANSAS
- 4 CALIFORNIA

```
In [14]: # Импьютация наиболее частыми значениями
           imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
           data_imp2 = imp2.fit_transform(cat_temp_data)
           data_imp2
Out[14]: array([['ALABAMA'], ['ALASKA'],
                 ['ARIZONA'],
                 ['WEST VIRGINIA'],
                 ['WISCONSIN'],
['WYOMING']], dtype=object)
In [15]: cat_enc = pd.DataFrame({'STATE':data_imp2.T[0]})
          cat_enc
                      STATE
Out[15]:
                    ALABAMA
             1
                     ALASKA
             2
                    ARIZONA
                  ARKANSAS
             3
                  CALIFORNIA
             4
          1710
                    VIRGINIA
          1711 WASHINGTON
          1712 WEST_VIRGINIA
          1713
                  WISCONSIN
          1714
                   WYOMING
         1715 rows x 1 columns
In [16]: from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

Кодирование категорий целочисленными значениями label encoding

```
In [17]: le = LabelEncoder()
    cat_enc_le = le.fit_transform(cat_enc['STATE'])
In [18]: cat_enc['STATE'].unique()
```

```
'MISSOURI', 'MONTANA', 'NEBRASKA', 'NEVADA', 'NEW_HAMPSHIRE',
                   'NEW_JERSEY', 'NEW_MEXICO', 'NEW_YORK', 'NORTH_CAROLINA',
                  'NORTH_DAKOTA', 'OHIO', 'OKLAHOMA', 'OREGON', 'PENNSYLVANIA', 'RHODE_ISLAND', 'SOUTH_CAROLINA', 'SOUTH_DAKOTA', 'TENNESSEE', 'TEXAS', 'UTAH', 'VERMONT', 'VIRGINIA', 'WASHINGTON', 'WEST_VIRGINIA', 'WISCONSIN', 'WYOMING', 'DODEA', 'NATIONAL'],
                  dtype=object)
In [19]: np.unique(cat_enc_le)
Out[19]: array([ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33,
                  34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52))
In [20]: le.inverse_transform([0, 1, 2, 3])
Out[20]: array(['ALABAMA', 'ALASKA', 'ARIZONA', 'ARKANSAS'], dtype=object)
          Кодирование категорий наборами бинарных значений -
          one-hot encoding
In [21]: ohe = OneHotEncoder()
            cat_enc_ohe = ohe.fit_transform(cat_enc[['STATE']])
In [22]: cat enc.shape
Out[22]: (1715, 1)
In [23]: cat_enc_ohe.shape
Out[23]: (1715, 53)
In [24]: cat_enc_ohe
Out[24]: <1715x53 sparse matrix of type '<class 'numpy.float64'>'
                    with 1715 stored elements in Compressed Sparse Row format>
```

In [25]: cat_enc_ohe.todense()[0:10]


```
0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   [0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
   0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   0., 0., 0., 0., 0.],
   [0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.,
```

In [26]: cat_enc.head(10)

Out[26];		STATE
	0	ALABAMA
	1	ALASKA
	2	ARIZONA
	3	ARKANSAS
	4	CALIFORNIA
	5	COLORADO
	6	CONNECTICUT
	7	DELAWARE
	8	DISTRICT_OF_COLUMBIA
	9	FLORIDA

```
In [27]: # Увеличенные диаграммы рассеяния sns.jointplot(x = "ENROLL", y = "TOTAL_REVENUE", kind="scatter", data = data
```

Out[27]: <seaborn.axisgrid.JointGrid at 0x7f8ba7251b20>



```
In [28]: fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='ENROLL', y='TOTAL_REVENUE', data=data, hue='OTHEI
```

Out[28]: <AxesSubplot:xlabel='ENROLL', ylabel='TOTAL_REVENUE'>

